Progetto Dataset

Componenti del gruppo:

Justin Cadena
Francesco Miraglia
Zhou Zencheng

Indice:

Introduzione:

Questo progetto si concentra sull'analisi di un dataset attraverso una serie di fasi ben definite. Iniziamo importando un file CSV contenente i dati che intendiamo esaminare e analizzare. Successivamente, modifichiamo il dataset, apportando eventuali correzioni o pulizie necessarie per garantire la coerenza e la qualità dei dati.

Dopo aver preparato il dataset, passiamo all'analisi dei dati, utilizzando grafici di correlazione e distribuzione per comprendere meglio la struttura e le relazioni tra le variabili presenti nei dati. Questo ci permette di ottenere insight significativi prima di procedere con ulteriori manipolazioni dei dati.

Affrontiamo poi il processo è la gestione dei valori mancanti e degli outlier. Identifichiamo i valori mancanti nel dataset e decidiamo come trattarli in modo appropriato per non compromettere l'analisi. Inoltre, individuiamo e gestiamo gli outlier presenti nei dati, poiché possono influenzare negativamente i risultati delle nostre analisi e dei modelli che costruiremo successivamente.

Successivamente, affrontiamo la codifica delle variabili categoriche e il ridimensionamento delle variabili, passaggi essenziali per preparare i dati per l'addestramento dei modelli di machine learning. La codifica delle variabili categoriche è necessaria perché molti algoritmi di machine learning richiedono dati numerici, mentre il ridimensionamento delle variabili può migliorare le prestazioni dei modelli riducendo la scala delle variabili.

Po dividiamo il dataset in set di addestramento e test, fondamentale per valutare l'efficacia dei modelli di machine learning e garantire che siano in grado di generalizzare bene su nuovi dati.

Infine procediamo con la creazione e la valutazione dei modelli di machine learning. In questo passaggio, selezioniamo gli algoritmi di apprendimento automatico e li addestriamo utilizzando il set di addestramento. In questo caso, abbiamo addestrato tre diversi modelli: regressione logistica, albero decisionale e random forest.

Dopo aver addestrato i modelli, li valutiamo utilizzando il set di test per determinare le loro prestazioni. In particolare, calcoliamo l'accuratezza di ciascun modello e generiamo rapporti di classificazione che forniscono ulteriori metriche di valutazione come precisione, richiamo e F1-score per ogni classe di output.

Una volta valutati i modelli, possiamo confrontare le loro prestazioni e scegliere quello che meglio si adatta alle nostre esigenze e obiettivi di analisi.

Questo progetto offre un dimostrazione di come esplorare i dati, applicare tecniche di analisi e la manipolazione dei dati, e costruire modelli di machine learning per ottenere informazioni e prendere decisioni.

1 Importo

[1]:
```
import pandas as pd

df = pd.read_csv(r'C:\\Users\\default\\titanic.csv')

print(df)
```

```
     passenger_id  pclass                                               name  \
0            1216       3                                 Smyth, Miss. Julia
1             699       3                                    Cacic, Mr. Luka
2            1267       3  Van Impe, Mrs. Jean Baptiste (Rosalie Paula Go...
3             449       2              Hocking, Mrs. Elizabeth (Eliza Needs)
4             576       2                                  Veal, Mr. James
..            ...     ...                                               ...
845           158       1                      Hipkins, Mr. William Edward
846           174       1                          Kent, Mr. Edward Austin
847           467       2                Kantor, Mrs. Sinai (Miriam Sternin)
848          1112       3                        Peacock, Miss. Treasteall
849           425       2                            Greenberg, Mr. Samuel

        sex   age  sibsp  parch             ticket     fare cabin embarked  \
0    female   NaN      0      0             335432   7.7333   NaN        Q
1      male  38.0      0      0             315089   8.6625   NaN        S
2    female  30.0      1      1             345773  24.1500   NaN        S
3    female  54.0      1      3              29105  23.0000   NaN        S
4      male  40.0      0      0              28221  13.0000   NaN        S
..      ...   ...    ...    ...                ...      ...   ...      ...
845    male  55.0      0      0                680  50.0000   C39        S
846    male  58.0      0      0              11771  29.7000   B37        C
847  female  24.0      1      0             244367  26.0000   NaN        S
848  female   3.0      1      1  SOTON/O.Q. 3101315  13.7750   NaN        S
849    male  52.0      0      0             250647  13.0000   NaN        S

    boat   body                 home.dest  survived
0     13    NaN                       NaN         1
1    NaN    NaN                   Croatia         0
2    NaN    NaN                       NaN         0
3      4    NaN      Cornwall / Akron, OH         1
4    NaN    NaN  Barre, Co Washington, VT         0
..   ...    ...                       ...       ...
845  NaN    NaN       London / Birmingham         0
846  NaN  258.0                Buffalo, NY         0
847   12    NaN        Moscow / Bronx, NY         1
848  NaN    NaN                       NaN         0
849  NaN   19.0                 Bronx, NY         0
```

[850 rows x 15 columns]

2 Modifica

---

[2]:
```
# Rinomina una colonna
df = df.rename(columns={
    'passenger_id': 'ID Passeggero',
    'pclass': 'Classe',
    'name': 'Nome',
    'sex': 'Sesso',
    'age': 'Età',
    'sibsp': 'Figli',
    'parch': 'Parenti',
    'ticket': 'Ticket',
    'fare': 'Tariffa',
    'cabin': 'Cabina',
    'embarked': 'Porto Imbarco',
    'boat': 'Scialuppa di salvataggio',
    'body': 'Numero del corpo',
    'home.dest': 'Destinazione',
    'survived': 'Sopravvissuti',
    })



# Aggiungi una nuova colonna
df.insert(15,'Vivi', 0)
df.insert(loc=0, column='Numero Passeggeri', value=range(1, len(df) + 1))

# Elimina una colonna
df = df.drop(columns=['Numero del corpo'])
df = df.drop(columns=['Cabina'])

print(df)
```

```
     Numero Passeggeri  ID Passeggero  Classe  \
0                    1           1216       3
1                    2            699       3
2                    3           1267       3
3                    4            449       2
4                    5            576       2
..                 ...            ...     ...
845                846            158       1
846                847            174       1
847                848            467       2
```

```
848                849           1112       3
849                850            425       2

                                                  Nome   Sesso   Età  Figli  \
0                                    Smyth, Miss. Julia  female   NaN      0
1                                       Cacic, Mr. Luka    male  38.0      0
2    Van Impe, Mrs. Jean Baptiste (Rosalie Paula Go...  female  30.0      1
3                Hocking, Mrs. Elizabeth (Eliza Needs)  female  54.0      1
4                                       Veal, Mr. James    male  40.0      0
..                                                  ...     ...   ...    ...
845                         Hipkins, Mr. William Edward    male  55.0      0
846                             Kent, Mr. Edward Austin    male  58.0      0
847                Kantor, Mrs. Sinai (Miriam Sternin)  female  24.0      1
848                           Peacock, Miss. Treasteall  female   3.0      1
849                               Greenberg, Mr. Samuel    male  52.0      0

     Parenti             Ticket  Tariffa Porto Imbarco  \
0          0             335432   7.7333             Q
1          0             315089   8.6625             S
2          1             345773  24.1500             S
3          3              29105  23.0000             S
4          0              28221  13.0000             S
..       ...                ...      ...           ...
845        0                680  50.0000             S
846        0              11771  29.7000             C
847        0             244367  26.0000             S
848        1  SOTON/O.Q. 3101315  13.7750             S
849        0             250647  13.0000             S

    Scialuppa di salvataggio             Destinazione  Sopravvissuti  Vivi
0                         13                      NaN              1     0
1                        NaN                  Croatia              0     0
2                        NaN                      NaN              0     0
3                          4     Cornwall / Akron, OH              1     0
4                        NaN  Barre, Co Washington, VT              0     0
..                       ...                      ...            ...   ...
845                      NaN      London / Birmingham              0     0
846                      NaN             Buffalo, NY               0     0
847                       12       Moscow / Bronx, NY              1     0
848                      NaN                      NaN              0     0
849                      NaN                Bronx, NY              0     0

[850 rows x 15 columns]
```

3 Salvataggio

[3]:
```
#Salva il file con le modifiche
df.to_csv(r'C:\\atmosphere\\titanic_saved.csv', index=False)

# Verifica del file salvato
df_verifica = pd.read_csv(r'C:\\atmosphere\\titanic_saved.csv')
print(df_verifica.head())
```

```
   Numero Passeggeri  ID Passeggero  Classe  \
0                  1           1216       3
1                  2            699       3
2                  3           1267       3
3                  4            449       2
4                  5            576       2

                                                Nome   Sesso   Età  Figli  \
0                                Smyth, Miss. Julia  female   NaN      0
1                                   Cacic, Mr. Luka    male  38.0      0
2  Van Impe, Mrs. Jean Baptiste (Rosalie Paula Go...  female  30.0      1
3              Hocking, Mrs. Elizabeth (Eliza Needs)  female  54.0      1
4                                   Veal, Mr. James    male  40.0      0

   Parenti  Ticket  Tariffa Porto Imbarco Scialuppa di salvataggio  \
0        0  335432   7.7333             Q                      13
1        0  315089   8.6625             S                     NaN
2        1  345773  24.1500             S                     NaN
3        3   29105  23.0000             S                       4
4        0   28221  13.0000             S                     NaN

              Destinazione  Sopravvissuti  Vivi
0                      NaN              1     0
1                  Croatia              0     0
2                      NaN              0     0
3      Cornwall / Akron, OH             1     0
4  Barre, Co Washington, VT             0     0
```

4 Grafici correlazione & distribuzione

[4]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# Seleziona le colonne desiderate
colonne_selezionate = ['Numero Passeggeri','Età', 'Figli', 'Parenti', 'Tariffa']
subset_df = df[colonne_selezionate]

#Matrice di correlazione
correlation_matrix = subset_df.corr()
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title("Matrice di correlazione")
plt.show()

# Scatter plot dispersione utilizzando i dati dal dataframe
plt.figure(figsize=(10, 6))
plt.scatter(subset_df['Numero Passeggeri'], subset_df['Età'],␣
 ↪subset_df['Classe'], label='Numero Passeggeri', color='black', alpha=0.7)
plt.scatter(subset_df['Numero Passeggeri'], subset_df['Età'],␣
 ↪subset_df['Classe'], label='Èta', color='blue', alpha=0.7)
plt.scatter(subset_df['Numero Passeggeri'], subset_df['Età'],␣
 ↪subset_df['Classe'], label='Classe', color='orange', alpha=0.7)
plt.xlabel('Numero Passeggeri')
plt.ylabel('Èta')
plt.title('Relazione tra Numero Passeggeri e Èta')
plt.legend()
plt.grid(True)
plt.show()
```

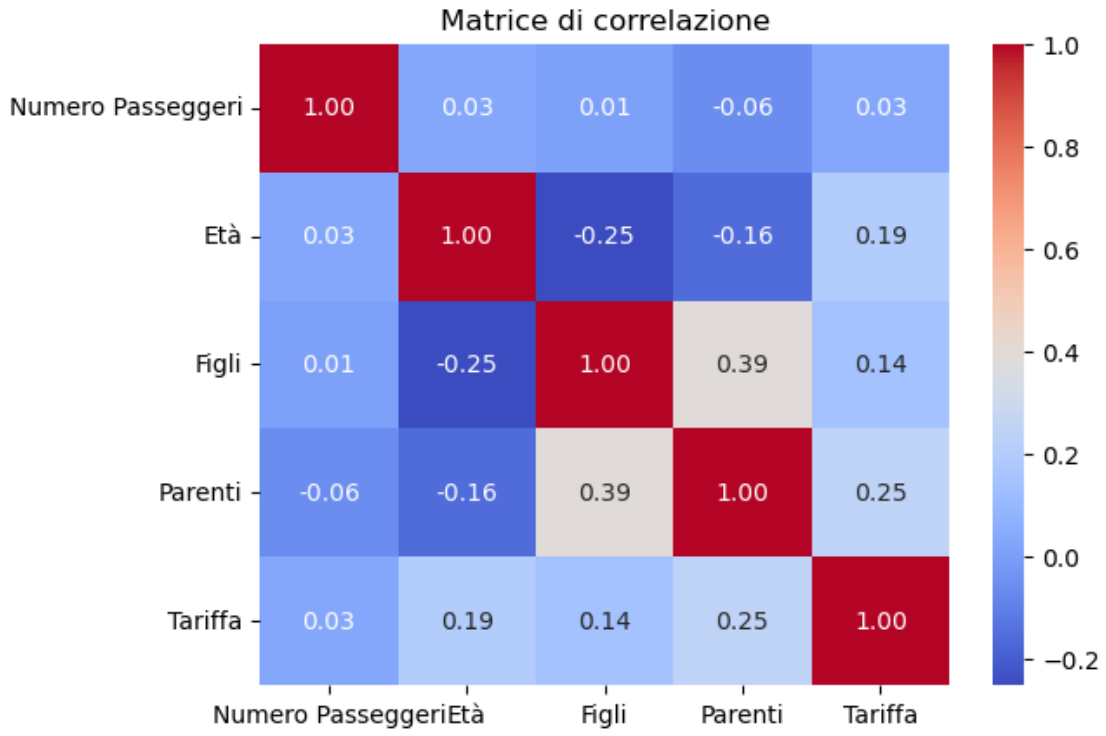


```
<Figure size 1000x600 with 0 Axes>
```

[5]:
```
# Plotting delle distribuzioni delle colonne
plt.figure(figsize=(6, 5))
subset_df.plot(kind='density', subplots=True, layout=(6, 2), sharex=False,␣
 ↪figsize=(15, 20))
plt.suptitle("Distribuzioni delle colonne")
plt.show()
```

```
<Figure size 600x500 with 0 Axes>
```

Distribuzioni delle colonne

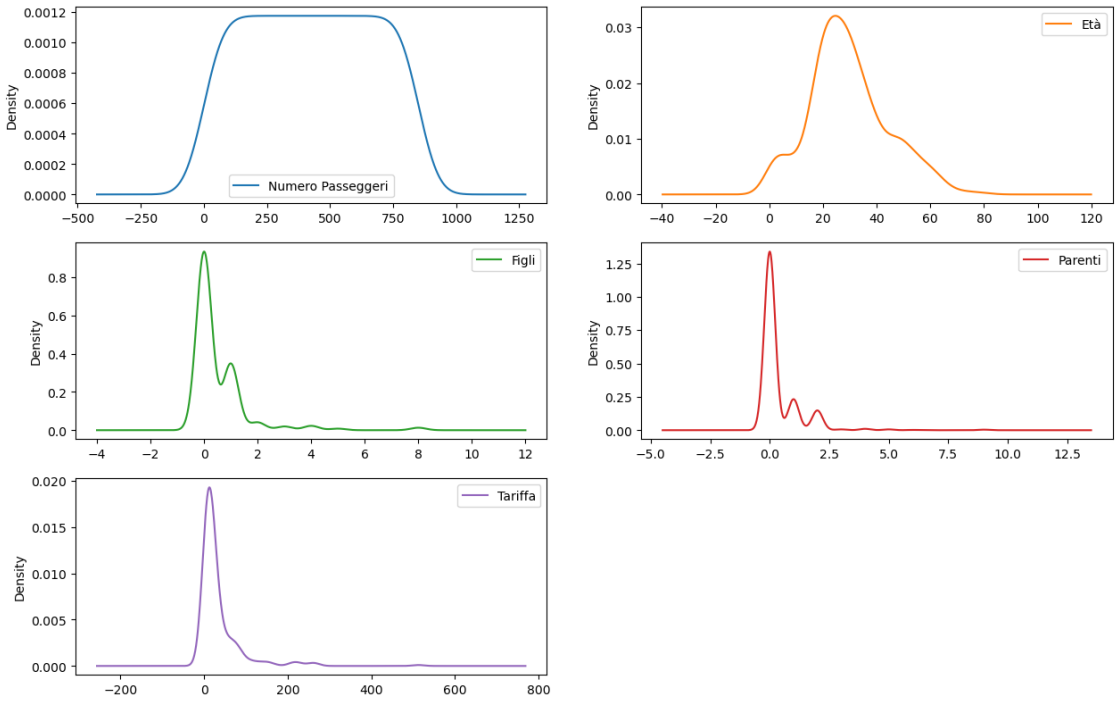

5 Missing values

[6]:
```
df.isna().any
```

[6]:
```
<bound method NDFrame._add_numeric_operations.<locals>.any of      Numero
Passeggeri  ID Passeggero  Classe   Nome  Sesso    Età  Figli  \
0                False          False   False  False  False   True  False
1                False          False   False  False  False  False  False
2                False          False   False  False  False  False  False
3                False          False   False  False  False  False  False
4                False          False   False  False  False  False  False
..                 ...            ...     ...    ...    ...    ...    ...
845              False          False   False  False  False  False  False
846              False          False   False  False  False  False  False
847              False          False   False  False  False  False  False
848              False          False   False  False  False  False  False
849              False          False   False  False  False  False  False

     Parenti  Ticket  Tariffa  Porto Imbarco  Scialuppa di salvataggio  \
0      False   False    False          False                     False
1      False   False    False          False                      True
2      False   False    False          False                      True
3      False   False    False          False                     False
4      False   False    False          False                      True
..       ...     ...      ...            ...                       ...
845    False   False    False          False                      True
846    False   False    False          False                      True
847    False   False    False          False                     False
848    False   False    False          False                      True
849    False   False    False          False                      True

     Destinazione  Sopravvissuti   Vivi
0            True          False  False
1           False          False  False
2            True          False  False
3           False          False  False
4           False          False  False
..            ...            ...    ...
845         False          False  False
846         False          False  False
847         False          False  False
848          True          False  False
849         False          False  False

[850 rows x 15 columns]>
```

[7]:
```
df.isna().sum()
```

[7]:
```
Numero Passeggeri            0
ID Passeggero                0
Classe                       0
Nome                         0
Sesso                        0
Età                        174
Figli                        0
Parenti                      0
Ticket                       0
Tariffa                      1
Porto Imbarco                1
Scialuppa di salvataggio   542
Destinazione               386
Sopravvissuti                0
Vivi                         0
dtype: int64
```

[8]:
```
missing_percent = (df.isnull().sum()  /len(df)) * 100
missing_percent
```

[8]:
```
Numero Passeggeri           0.000000
ID Passeggero               0.000000
Classe                      0.000000
Nome                        0.000000
Sesso                       0.000000
Età                        20.470588
Figli                       0.000000
Parenti                     0.000000
Ticket                      0.000000
Tariffa                     0.117647
Porto Imbarco               0.117647
Scialuppa di salvataggio   63.764706
Destinazione               45.411765
Sopravvissuti               0.000000
Vivi                        0.000000
dtype: float64
```

[9]:
```
import matplotlib.pyplot as plt

# Creazione della lista dei colori per le barre, utilizzando 'lightblue' se la␣
 ↪percentuale di valori mancanti è inferiore a 0.5, altrimenti 'lightcoral'
colors = ['lightblue' if val < 0.5 else 'lightcoral' for val in missing_percent]

# Creazione di una nuova figura con dimensioni specifiche
plt.figure(figsize=(10, 6))
```

```
# Creazione del grafico a barre orizzontali, con colori definiti dalla lista␣
↪'colors' e trasparenza impostata a 0.8
missing_percent.plot(kind='barh', color=colors, alpha=0.8)

# Aggiunta di etichette agli assi x e y del grafico e un titolo
plt.xlabel('Percentuale di Missing Values')
plt.ylabel('Variabili')
plt.title('Analisi dei Missing Values per Variabile')

# Aggiunta di una griglia solo sull'asse x del grafico
plt.grid(axis='x')

# Visualizzazione del grafico
plt.show()
```

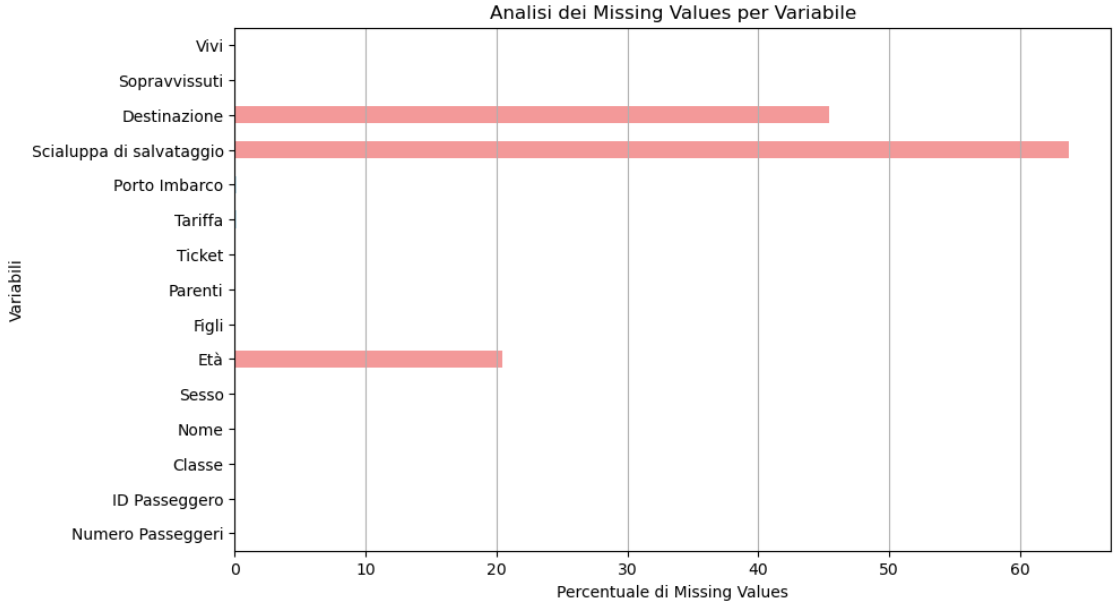

[10]:
```
import pandas as pd

# Carica il dataset
df = pd.read_csv(r'C:\\atmosphere\\titanic_saved.csv')

# Converti la colonna 'Scialuppa di salvataggio' in numeri, ignorando i valori␣
↪non convertibili
df['Scialuppa di salvataggio'] = pd.to_numeric(df['Scialuppa di salvataggio'],␣
↪errors='coerce')
```

```python
# Calcola la media della colonna 'Èta' e 'Scialuppa di salvataggio'
eta_media = df['Età'].mean()
scialuppa_media = df['Scialuppa di salvataggio'].mean()

print("Media dell'età:", eta_media)
print("Media della scialuppa di salvataggio:", scialuppa_media)

# Elimina le righe con valori mancanti nelle colonne 'Destinazione', 'Tariffa' e␣
↪'Porto Imbarco'
df.dropna(subset=['Destinazione', 'Tariffa', 'Porto Imbarco'], inplace=True)

# Sostituisci i valori NaN con punti interrogativi
df.fillna('?', inplace=True)

# Visualizza il dataframe senza le righe contenenti NaN nelle colonne specificate
print(df)
```

```
Media dell'età: 29.519847189349115
Media della scialuppa di salvataggio: 9.421686746987952
     Numero Passeggeri  ID Passeggero  Classe  \
1                    2            699       3
3                    4            449       2
4                    5            576       2
7                    8            560       2
10                  11            313       1
..                 ...            ...     ...
844                845            165       1
845                846            158       1
846                847            174       1
847                848            467       2
849                850            425       2

                                     Nome   Sesso   Età  Figli  Parenti  \
1                          Cacic, Mr. Luka    male  38.0      0        0
3    Hocking, Mrs. Elizabeth (Eliza Needs)  female  54.0      1        3
4                          Veal, Mr. James    male  40.0      0        0
7                    Sinkkonen, Miss. Anna  female  30.0      0        0
10                Widener, Mr. Harry Elkins    male  27.0      0        2
..                                      ...     ...   ...    ...      ...
844           Hoyt, Mr. Frederick Maxfield    male  38.0      1        0
845            Hipkins, Mr. William Edward    male  55.0      0        0
846                Kent, Mr. Edward Austin    male  58.0      0        0
847    Kantor, Mrs. Sinai (Miriam Sternin)  female  24.0      1        0
849                  Greenberg, Mr. Samuel    male  52.0      0        0

     Ticket   Tariffa Porto Imbarco Scialuppa di salvataggio  \
1    315089    8.6625             S                       ?
3     29105   23.0000             S                     4.0
```

```
4     28221   13.0000            S                      ?
7    250648   13.0000            S                   10.0
10   113503  211.5000            C                      ?
..      ...       ...          ...                    ...
846   11771   29.7000            C                      ?
847  244367   26.0000            S                   12.0
849  250647   13.0000            S                      ?

                    Destinazione  Sopravvissuti  Vivi
1                        Croatia              0     0
3            Cornwall / Akron, OH             1     0
4       Barre, Co Washington, VT              0     0
7       Finland / Washington, DC              1     0
10                Elkins Park, PA             0     0
..                            ...           ...   ...
846                   Buffalo, NY             0     0
847            Moscow / Bronx, NY             1     0
849                     Bronx, NY             0     0

[464 rows x 15 columns]
```

[11]:
```python
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Calcola la matrice di correlazione
corr_matrix = df.corr()

# Crea una heatmap della matrice di correlazione
plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title('Matrice di Correlazione tra Variabili', fontsize=16)
plt.show()
```

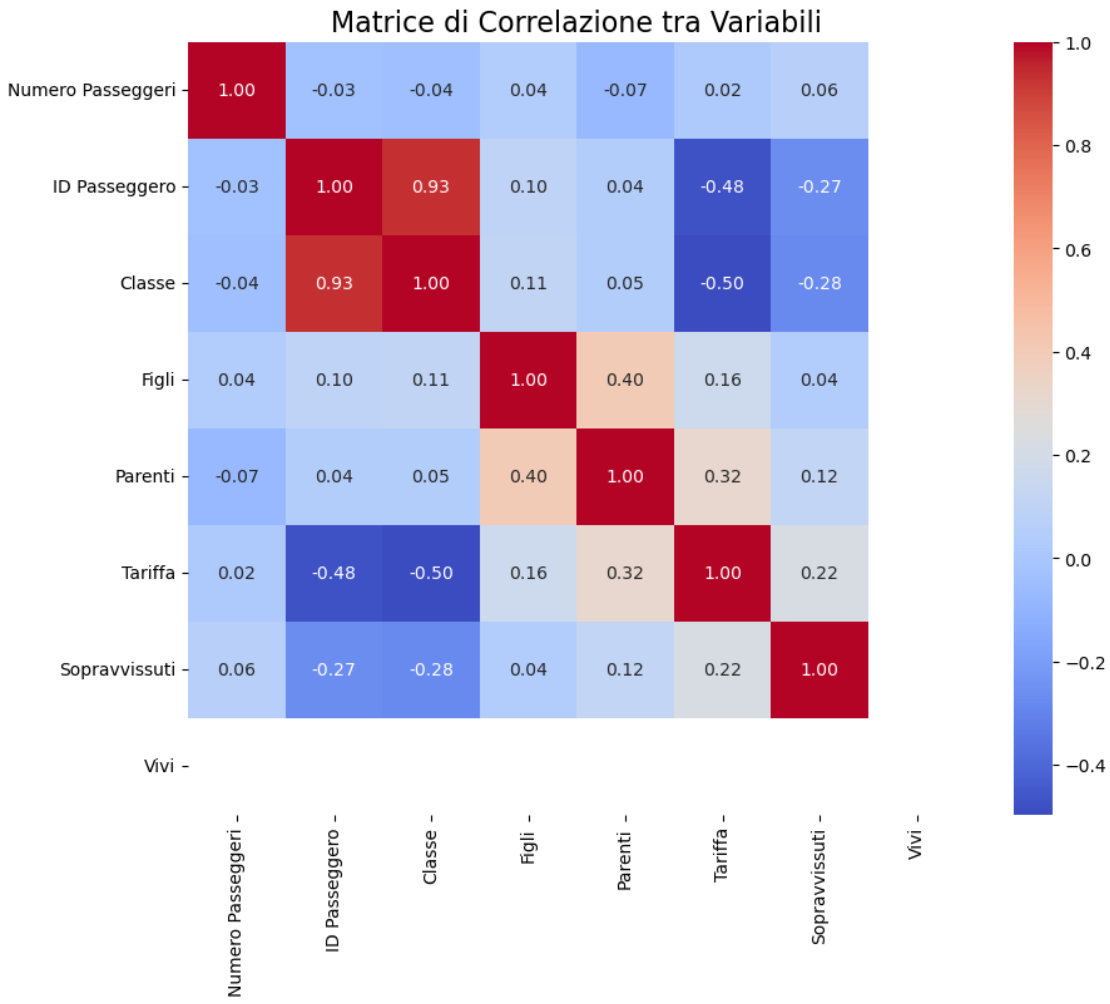

[12]:
```
df.isna().sum()
```

[12]:
```
Numero Passeggeri           0
ID Passeggero               0
Classe                      0
Nome                        0
Sesso                       0
Età                         0
Figli                       0
Parenti                     0
Ticket                      0
Tariffa                     0
Porto Imbarco               0
Scialuppa di salvataggio    0
Destinazione                0
Sopravvissuti               0
```

```
Vivi                        0
dtype: int64
```

6 Outliers

---

[13]:
```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt


df = pd.read_csv(r'C:\\atmosphere\\titanic_saved.csv')

# Crea una nuova figura con dimensioni specifiche
plt.figure(figsize=(16,5))

# Crea un subplot con una riga e due colonne, e seleziona il primo subplot
plt.subplot(1,2,1)

# Utilizza seaborn per creare un grafico della distribuzione dell'età
sns.distplot(df['Età'])

# Sostituisci i valori mancanti nell'intero DataFrame con 0
df.fillna(0, inplace=True)

# Crea il secondo subplot
plt.subplot(1,2,2)
sns.distplot(df['Tariffa'])
plt.show()
```

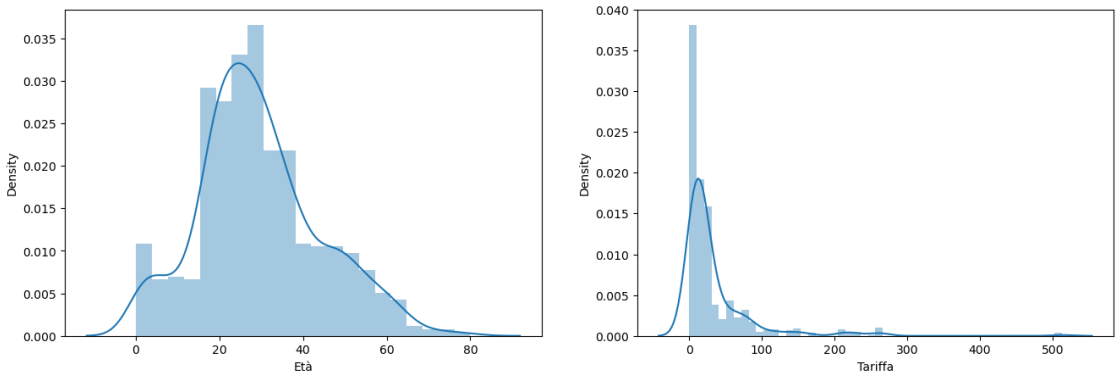

[14]:
```
print("Media Età",df['Età'].mean())
print("Deviazione Standart Età", df['Età'].std())
```

```
print("Media Tariffa",df['Tariffa'].mean())
print("Deviazione Standart Tariffa", df['Tariffa'].std())
```

```
Media Età 23.476960823529414
Deviazione Standart Età 17.624806369856714
Media Tariffa 33.972686
Deviazione Standart Tariffa 53.68681811921515
```

[15]:
```
import pandas as pd

# Calcola i limiti superiori e inferiori per identificare gli outlier
upper_limit = df['Età'].mean() + 3 * df['Età'].std()
lower_limit = df['Età'].mean() - 3 * df['Età'].std()

# Seleziona le righe che sono al di fuori dei limiti
outliers_eta = df[(df['Età'] > upper_limit) | (df['Età'] < lower_limit)]
outliers_eta
```

[15]:
```
     Numero Passeggeri  ID Passeggero  Classe  \
177                178             14       1

                                      Nome Sesso   Età  Figli  Parenti Ticket  \
177  Barkworth, Mr. Algernon Henry Wilson  male  80.0      0        0  27042

     Tariffa Porto Imbarco Scialuppa di salvataggio   Destinazione  \
177     30.0             S                        B  Hessle, Yorks

     Sopravvissuti  Vivi
177              1     0
```

[16]:
```
import pandas as pd

# Calcola i limiti superiori e inferiori per identificare gli outlier
upper_limit = df['Tariffa'].mean() + 3 * df['Tariffa'].std()
lower_limit = df['Tariffa'].mean() - 3 * df['Tariffa'].std()

# Seleziona le righe che sono al di fuori dei limiti
outliers_tariffa = df[(df['Tariffa'] > upper_limit) | (df['Tariffa'] <␣
↪lower_limit)]
outliers_tariffa
```

[16]:
```
     Numero Passeggeri  ID Passeggero  Classe  \
10                  11            313       1
37                  38            249       1
60                  61             50       1
62                  63            173       1
169                170            193       1
171                172            180       1
```

229	230	112	1
231	232	10	1
247	248	115	1
311	312	250	1
339	340	66	1
369	370	251	1
374	375	23	1
403	404	17	1
436	437	35	1
464	465	285	1
521	522	237	1
623	624	286	1
649	650	11	1
710	711	129	1
714	715	116	1
719	720	314	1
766	767	24	1
790	791	183	1
796	797	49	1
804	805	312	1
826	827	253	1

	Nome	Sesso	Età	Figli	\
10	Widener, Mr. Harry Elkins	male	27.0	0	
37	Ryerson, Master. John Borie	male	13.0	2	
60	Cardeza, Mrs. James Warburton Martinez (Charlo...	female	58.0	0	
62	Keeping, Mr. Edwin	male	32.5	0	
169	Madill, Miss. Georgette Alexandra	female	15.0	0	
171	Kreuchen, Miss. Emilie	female	39.0	0	
229	Fortune, Miss. Ethel Flora	female	28.0	3	
231	Astor, Col. John Jacob	male	47.0	1	
247	Fortune, Mr. Mark	male	64.0	1	
311	Ryerson, Miss. Emily Borie	female	18.0	2	
339	Chaudanson, Miss. Victorine	female	36.0	0	
369	Ryerson, Miss. Susan Parker "Suzette"	female	21.0	2	
374	Bidois, Miss. Rosalie	female	42.0	0	
403	Baxter, Mrs. James (Helene DeLaudeniere Chaput)	female	50.0	0	
436	Bowen, Miss. Grace Scott	female	45.0	0	
464	Straus, Mr. Isidor	male	67.0	1	
521	Robbins, Mr. Victor	male	0.0	0	
623	Straus, Mrs. Isidor (Rosalie Ida Blun)	female	63.0	1	
649	Astor, Mrs. John Jacob (Madeleine Talmadge Force)	female	18.0	1	
710	Geiger, Miss. Amalie	female	35.0	0	
714	Fortune, Mrs. Mark (Mary McDougald)	female	60.0	1	
719	Widener, Mrs. George Dunton (Eleanor Elkins)	female	50.0	1	
766	Bird, Miss. Ellen	female	29.0	0	
790	Lesurer, Mr. Gustave J	male	35.0	0	

796	Cardeza, Mr. Thomas Drake Martinez	male	36.0	0		
804	Widener, Mr. George Dunton	male	50.0	1		
826	Ryerson, Mrs. Arthur Larned (Emily Maria Borie)	female	48.0	1		

	Parenti	Ticket	Tariffa	Porto Imbarco	Scialuppa di salvataggio	\
10	2	113503	211.5000	C	0	
37	2	PC 17608	262.3750	C	4	
60	1	PC 17755	512.3292	C	3	
62	0	113503	211.5000	C	0	
169	1	24160	211.3375	S	2	
171	0	24160	211.3375	S	2	
229	2	19950	263.0000	S	10	
231	0	PC 17757	227.5250	C	0	
247	4	19950	263.0000	S	0	
311	2	PC 17608	262.3750	C	4	
339	0	PC 17608	262.3750	C	4	
369	2	PC 17608	262.3750	C	4	
374	0	PC 17757	227.5250	C	4	
403	1	PC 17558	247.5208	C	6	
436	0	PC 17608	262.3750	C	4	
464	0	PC 17483	221.7792	S	0	
521	0	PC 17757	227.5250	C	0	
623	0	PC 17483	221.7792	S	0	
649	0	PC 17757	227.5250	C	4	
710	0	113503	211.5000	C	4	
714	4	19950	263.0000	S	10	
719	1	113503	211.5000	C	4	
766	0	PC 17483	221.7792	S	8	
790	0	PC 17755	512.3292	C	3	
796	1	PC 17755	512.3292	C	3	
804	1	113503	211.5000	C	0	
826	3	PC 17608	262.3750	C	4	

	Destinazione	Sopravvissuti	Vivi
10	Elkins Park, PA	0	0
37	Haverford, PA / Cooperstown, NY	1	0
60	Germantown, Philadelphia, PA	1	0
62	0	0	0
169	St Louis, MO	1	0
171	0	1	0
229	Winnipeg, MB	1	0
231	New York, NY	0	0
247	Winnipeg, MB	0	0
311	Haverford, PA / Cooperstown, NY	1	0
339	0	1	0
369	Haverford, PA / Cooperstown, NY	1	0
374	0	1	0

403	Montreal, PQ	1	0
436	Cooperstown, NY	1	0
464	New York, NY	0	0
521	0	0	0
623	New York, NY	0	0
649	New York, NY	1	0
710	0	1	0
714	Winnipeg, MB	1	0
719	Elkins Park, PA	1	0
766	0	1	0
790	0	1	0
796	Austria-Hungary / Germantown, Philadelphia, PA	1	0
804	Elkins Park, PA	0	0
826	Haverford, PA / Cooperstown, NY	1	0

[17]:
```
sns.boxplot(df)
plt.xticks(rotation=60)
```

[17]: <Axes: >

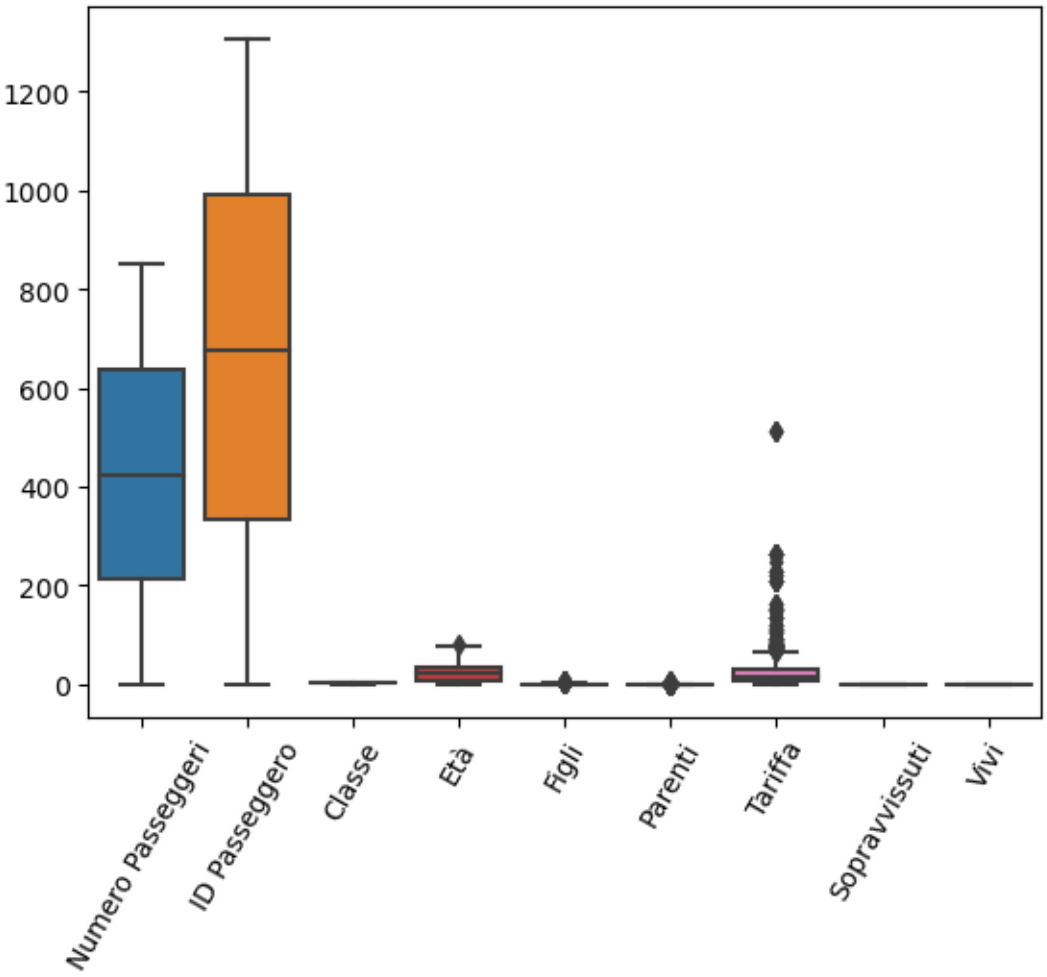

7 Encoding & Scaling

[18]:
```
from sklearn.preprocessing import StandardScaler
import pandas as pd

new_data = df[['Numero Passeggeri', 'ID Passeggero', 'Classe', 'Nome', 'Sesso',␣
 ↪'Età', 'Figli', 'Parenti', 'Ticket', 'Tariffa', 'Porto Imbarco', 'Scialuppa di␣
 ↪salvataggio', 'Destinazione', 'Sopravvissuti', 'Vivi']]
new_data.head()
```

[18]:

	Numero Passeggeri	ID Passeggero	Classe	Nome	Sesso	Età	Figli	Parenti	Ticket	Tariffa	Porto Imbarco	Scialuppa di salvataggio	Destinazione	Sopravvissuti	Vivi
0	1	1216	3	Smyth, Miss. Julia	female	0.0	0	0	335432	7.7333	Q	13	0	1	0
1	2	699	3	Cacic, Mr. Luka	male	38.0	0	0	315089	8.6625	S	0	Croatia	0	0
2	3	1267	3	Van Impe, Mrs. Jean Baptiste (Rosalie Paula Go...	female	30.0	1	1	345773	24.1500	S	0	0	0	0
3	4	449	2	Hocking, Mrs. Elizabeth (Eliza Needs)	female	54.0	1	3	29105	23.0000	S	4	Cornwall / Akron, OH	1	0
4	5	576	2	Veal, Mr. James	male	40.0	0	0	28221	13.0000	S	0	Barre, Co Washington, VT	0	0

[19]:
```
from sklearn.preprocessing import LabelEncoder

lb = LabelEncoder()  # Crea un'istanza della classe LabelEncoder

# Definizione di una funzione personalizzata per codificare una colonna usando␣
 ↪LabelEncoder
def myfuc(x, c):
    x = x.astype(str)  # Converti tutti i valori della colonna in stringhe
    m = lb.fit(x)  # Addestra il LabelEncoder sulla colonna
    p = lb.transform(x)  # Trasforma i valori della colonna
    df = pd.DataFrame(p, columns=[c])  # Crea un DataFrame con i valori␣
 ↪trasformati
    return df

mylist = []  # Inizializza una lista vuota per contenere i DataFrame trasformati

# Iterazione su tutte le colonne del DataFrame 'new_data'
for item in new_data.columns:
    new = myfuc(new_data[item], item)  # Applica la funzione personalizzata a␣
 ↪ciascuna colonna
    mylist.append(new)  # Aggiungi il DataFrame risultante alla lista 'mylist'

mylist = tuple(mylist)  # Converti la lista in una tupla
new_encode = pd.concat(mylist, axis=1)  # Concatena tutti i DataFrame nella␣
 ↪tupla lungo l'asse delle colonne

new_encode  # Mostra il DataFrame risultante
```

[19]:

	Numero Passeggeri	ID Passeggero	Classe	Nome	Sesso	Età	Figli	\
0	0	159	2	736	0	0	0	
1	111	626	2	123	1	45	0	
2	222	197	2	783	0	35	1	
3	333	452	1	360	0	66	1	
4	444	534	1	792	1	49	0	
..	...	...	...	...	...	...	...	
845	829	246	0	353	1	67	0	
846	830	260	0	426	1	71	0	
847	831	467	1	411	0	26	1	
848	832	79	2	613	0	34	1	
849	834	436	1	309	1	64	0	

	Parenti	Ticket	Tariffa	Porto Imbarco	Scialuppa di salvataggio	\
0	0	283	177	2	5	
1	0	257	212	3	0	
2	1	307	77	3	0	
3	3	237	73	3	14	
4	0	228	20	3	0	

```
..       ...     ...      ...             ...                         ...
845        0     488      130               3                           0
846        0      58       99               1                           0
847        0     145       84               3                           4
848        1     630       23               3                           0
849        0     160       20               3                           0

     Destinazione  Sopravvissuti  Vivi
0               0              1     0
1              57              0     0
2               0              0     0
3              53              1     0
4              12              0     0
..            ...            ...   ...
845           140              0     0
846            36              0     0
847           167              1     0
848             0              0     0
849            28              0     0

[850 rows x 15 columns]
```

[21]:
```python
import pandas as pd
import matplotlib.pyplot as plt

# Seleziona le colonne di interesse nel DataFrame 'df'
selected_columns = ['Numero Passeggeri', 'Classe', 'Età', 'Tariffa',␣
↪'Sopravvissuti']

# Inizializza un dizionario per memorizzare il conteggio delle diverse categorie␣
↪per ogni colonna selezionata
category_counts = {}

# Calcola il conteggio delle diverse categorie per ogni colonna selezionata
for col in selected_columns:
    category_counts[col] = df[col].value_counts()

# Crea un nuovo grafico con dimensioni specificate
plt.figure(figsize=(16, 8))

# Itera su tutte le colonne selezionate e crea un subplot per ciascuna colonna
for i, col in enumerate(selected_columns):
    plt.subplot(2, 3, i+1)  # Crea un subplot in una griglia 2x3, selezionando␣
↪l'indice 'i+1'
    category_counts[col].plot(kind='bar', color='skyblue', alpha=0.7, label=col)␣
↪ # Crea un grafico a barre per il conteggio delle categorie
    plt.title('Distribuzione delle Categorie')  # Aggiungi un titolo al subplot
```

```
    plt.xlabel('Categoria')  # Aggiungi un'etichetta all'asse x
    plt.ylabel('Conteggio')  # Aggiungi un'etichetta all'asse y

plt.tight_layout()  # Ottimizza la disposizione dei subplot
plt.show()
```

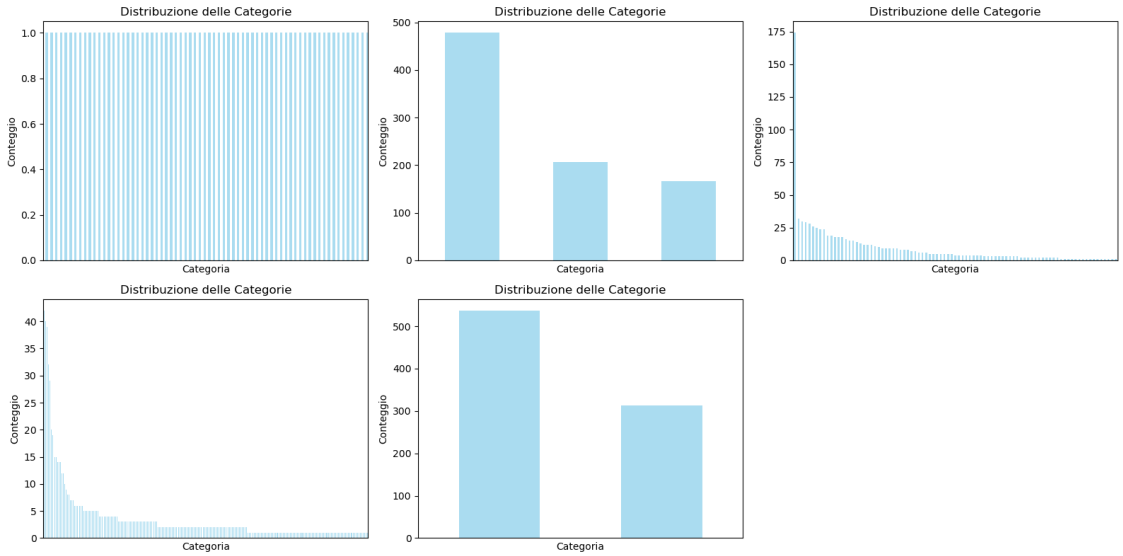

[22]:
```
from sklearn.preprocessing import StandardScaler

# Seleziona solo le colonne numeriche dal DataFrame
numeric_columns = df.select_dtypes(include=['float64', 'int64']).columns

# Inizializza lo scaler
st = StandardScaler()

# Adatta lo scaler ai dati delle colonne numeriche
st.fit(df[numeric_columns])

# Esegui lo scaling dei dati
scaled_data = st.transform(df[numeric_columns])

# Crea un nuovo DataFrame con i dati scalati
scaled_df = pd.DataFrame(scaled_data, columns=numeric_columns)

print("DataFrame originale:")
print(df)
print("\nDataFrame con dati scalati:")
print(scaled_df)
```

```
DataFrame originale:
```

```
     Numero Passeggeri  ID Passeggero  Classe  \
0                    1           1216       3
1                    2            699       3
2                    3           1267       3
3                    4            449       2
4                    5            576       2
..                 ...            ...     ...
845                846            158       1
846                847            174       1
847                848            467       2
848                849           1112       3
849                850            425       2

                                                Nome   Sesso   Età  Figli  \
0                                  Smyth, Miss. Julia  female   0.0      0
1                                     Cacic, Mr. Luka    male  38.0      0
2    Van Impe, Mrs. Jean Baptiste (Rosalie Paula Go...  female  30.0      1
3                Hocking, Mrs. Elizabeth (Eliza Needs)  female  54.0      1
4                                     Veal, Mr. James    male  40.0      0
..                                                ...     ...   ...    ...
845                         Hipkins, Mr. William Edward    male  55.0      0
846                             Kent, Mr. Edward Austin    male  58.0      0
847                Kantor, Mrs. Sinai (Miriam Sternin)  female  24.0      1
848                           Peacock, Miss. Treasteall  female   3.0      1
849                              Greenberg, Mr. Samuel    male  52.0      0

     Parenti             Ticket  Tariffa Porto Imbarco  \
0          0             335432   7.7333             Q
1          0             315089   8.6625             S
2          1             345773  24.1500             S
3          3              29105  23.0000             S
4          0              28221  13.0000             S
..       ...                ...      ...           ...
845        0                680  50.0000             S
846        0              11771  29.7000             C
847        0             244367  26.0000             S
848        1  SOTON/O.Q. 3101315  13.7750             S
849        0             250647  13.0000             S

    Scialuppa di salvataggio             Destinazione  Sopravvissuti  Vivi
0                         13                        0              1     0
1                          0                  Croatia              0     0
2                          0                        0              0     0
3                          4     Cornwall / Akron, OH              1     0
4                          0  Barre, Co Washington, VT              0     0
..                       ...                      ...            ...   ...
845                        0      London / Birmingham              0     0
846                        0              Buffalo, NY              0     0
```

```
847                      12        Moscow / Bronx, NY             1     0
848                       0                         0             0     0
849                       0                 Bronx, NY             0     0

[850 rows x 15 columns]

DataFrame con dati scalati:
     Numero Passeggeri  ID Passeggero    Classe       Età     Figli   Parenti  \
0            -1.730014       1.453727  0.811420 -1.332825 -0.469963 -0.434989
1            -1.725939       0.095088  0.811420  0.824496 -0.469963 -0.434989
2            -1.721863       1.587751  0.811420  0.370323  0.429741  0.702675
3            -1.717788      -0.561894 -0.381845  1.732842  0.429741  2.978005
4            -1.713713      -0.228147 -0.381845  0.938040 -0.469963 -0.434989
..                 ...            ...       ...       ...       ...       ...
845           1.713713      -1.326621 -1.575110  1.789614 -0.469963 -0.434989
846           1.717788      -1.284575 -1.575110  1.959929 -0.469963 -0.434989
847           1.721863      -0.514592 -0.381845  0.029694  0.429741 -0.434989
848           1.725939       1.180422  0.811420 -1.162510  0.429741  0.702675
849           1.730014      -0.624965 -0.381845  1.619299 -0.469963 -0.434989

      Tariffa  Sopravvissuti  Vivi
0   -0.489037       1.309830   0.0
1   -0.471719      -0.763458   0.0
2   -0.183070      -0.763458   0.0
3   -0.204504       1.309830   0.0
4   -0.390879      -0.763458   0.0
..        ...            ...   ...
845  0.298709      -0.763458   0.0
846 -0.079632      -0.763458   0.0
847 -0.148591       1.309830   0.0
848 -0.376435      -0.763458   0.0
849 -0.390879      -0.763458   0.0

[850 rows x 9 columns]
```

[23]:
```python
import matplotlib.pyplot as plt

# Visualizzazione delle distribuzioni delle colonne selezionate prima dello␣
 ↪scaling
selected_columns = ['Età', 'Tariffa']

# Crea una nuova figura con dimensioni specificate
plt.figure(figsize=(6, 6))

# Itera su tutte le colonne selezionate e crea un subplot per ciascuna colonna
for i, col in enumerate(selected_columns):
```

```
    plt.subplot(2, len(selected_columns)//2, i+1)  # Crea un subplot in una␣
 ↪griglia 2x2, selezionando l'indice 'i+1'
    plt.hist(df[col], bins=20, color='blue', alpha=0.5)  # Crea un istogramma␣
 ↪dei valori della colonna
    plt.title(col + ' (Prima dello Scaling)')  # Aggiungi un titolo al subplot
    plt.xlabel(col)  # Aggiungi un'etichetta all'asse x
    plt.ylabel('Frequenza')  # Aggiungi un'etichetta all'asse y

plt.tight_layout()  # Ottimizza la disposizione dei subplot
plt.show()  # Mostra il grafico

# Visualizzazione delle distribuzioni delle colonne selezionate dopo lo scaling
plt.figure(figsize=(6, 6))

# Itera su tutte le colonne selezionate e crea un subplot per ciascuna colonna
for i, col in enumerate(selected_columns):
    plt.subplot(2, len(selected_columns)//2, i+1)  # Crea un subplot in una␣
 ↪griglia 2x2, selezionando l'indice 'i+1'
    plt.hist(scaled_df[col], bins=20, color='red', alpha=0.5)  # Crea un␣
 ↪istogramma dei valori della colonna dopo lo scaling
    plt.title(col + ' (Dopo lo Scaling)')  # Aggiungi un titolo al subplot
    plt.xlabel(col)  # Aggiungi un'etichetta all'asse x
    plt.ylabel('Frequenza')  # Aggiungi un'etichetta all'asse y

plt.tight_layout()
plt.show()
```

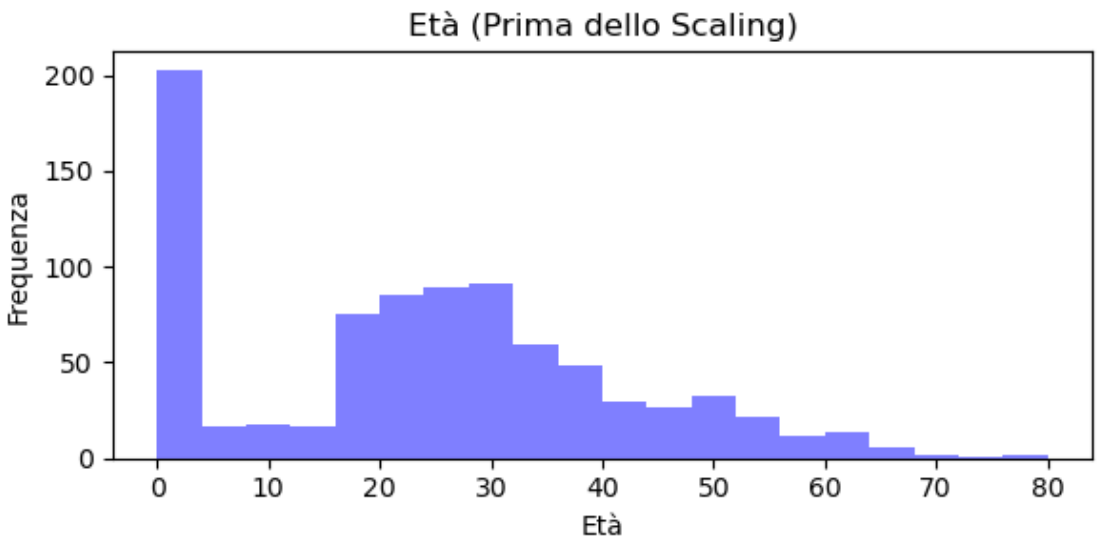
Età (Prima dello Scaling)
Frequenza
Età
0
50
100
150
200
0
10
20
30
40
50
60
70
80

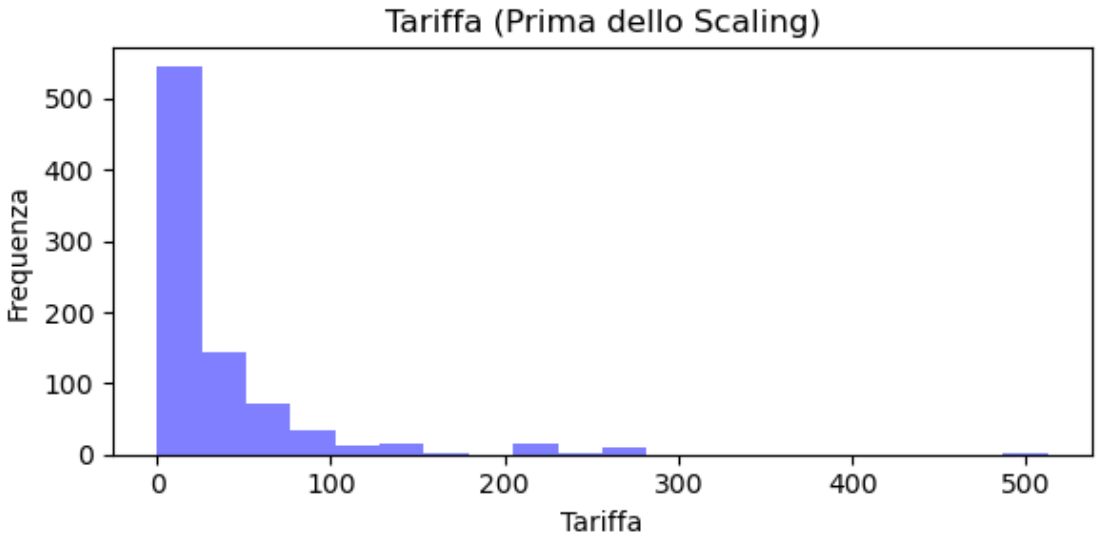
Tariffa (Prima dello Scaling)
Frequenza
Tariffa
0
100
200
300
400
500
0
100
200
300
400
500

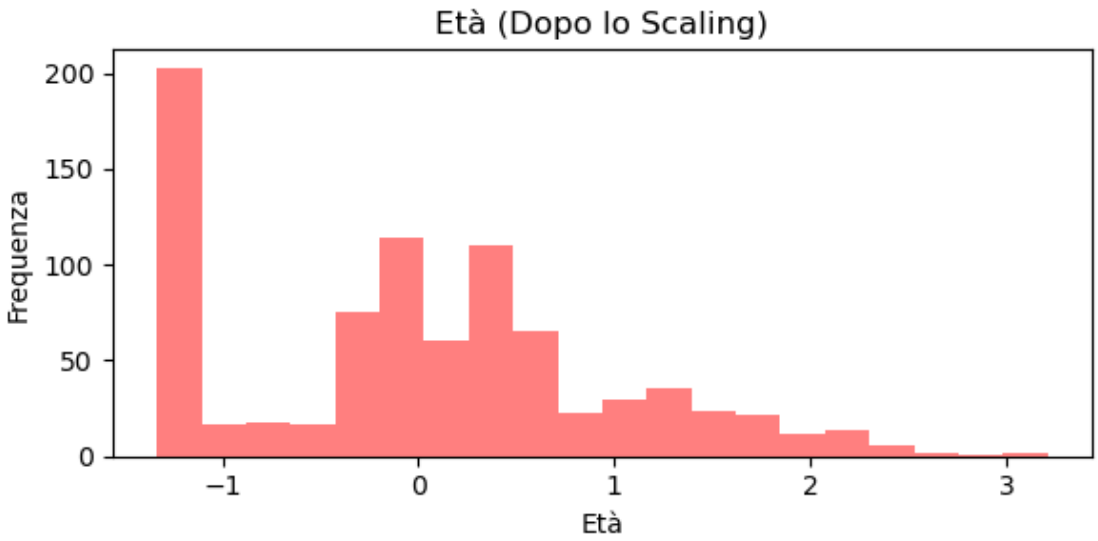
Età (Dopo lo Scaling)
Frequenza
200
150
100
50
0
−1
0
1
2
3
Età

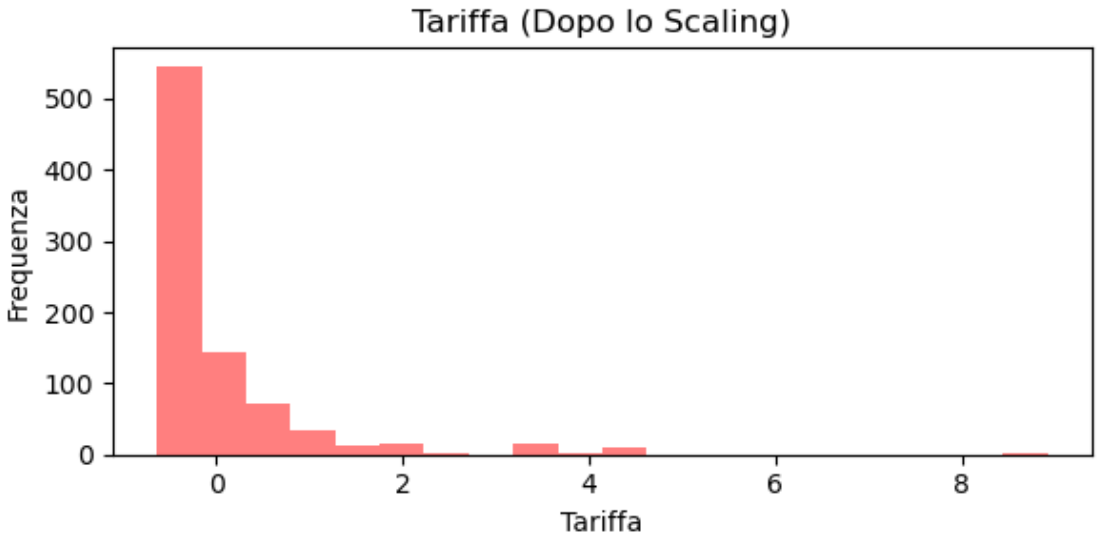
Tariffa (Dopo lo Scaling)
Frequenza
500
400
300
200
100
0
0
2
4
6
8
Tariffa

8 Splitting Dataset

[24]:
```
from sklearn.model_selection import train_test_split

# Dividi il dataset in set di addestramento e set di test
X_train, X_test, y_train, y_test = train_test_split(df[['Età', 'Sesso']],␣
 ↪df['Sopravvissuti'], test_size=0.25, random_state=42)

# Calcola il numero di sopravvissuti per età e sesso nel set di addestramento
survived_train = X_train.join(y_train).groupby(['Età',␣
 ↪'Sesso'])['Sopravvissuti'].sum()

# Calcola il numero di sopravvissuti per età e sesso nel set di test
survived_test = X_test.join(y_test).groupby(['Età', 'Sesso'])['Sopravvissuti'].
 ↪sum()

print("Numero di sopravvissuti per età e sesso nel set di addestramento:")
print(survived_train)
print("\nNumero di sopravvissuti per età e sesso nel set di test:")
print(survived_test)
```

```
Numero di sopravvissuti per età e sesso nel set di addestramento:
Età      Sesso
0.0000   female    22
         male      10
0.1667   female     1
0.4167   male       1
0.6667   male       1
                   ..
67.0000  male       0
70.0000  male       0
74.0000  male       0
76.0000  female     1
80.0000  male       1
Name: Sopravvissuti, Length: 139, dtype: int64

Numero di sopravvissuti per età e sesso nel set di test:
Età      Sesso
0.0000   female    10
         male       5
0.9167   male       1
1.0000   male       1
2.0000   male       1
                   ..
60.0000  male       0
61.0000  male       0
```

```
62.0000  male       0
63.0000  male       0
64.0000  male       0
Name: Sopravvissuti, Length: 87, dtype: int64
```

[25]:
```
import numpy as np

# Estrai i dati per il set di addestramento e di test
ages_train = survived_train['Età']
ages_test = survived_test['Età']
survived_male_train = survived_train[survived_train['Sesso'] ==␣
↪'male']['Sopravvissuti']
survived_female_train = survived_train[survived_train['Sesso'] ==␣
↪'female']['Sopravvissuti']
survived_male_test = survived_test[survived_test['Sesso'] ==␣
↪'male']['Sopravvissuti']
survived_female_test = survived_test[survived_test['Sesso'] ==␣
↪'female']['Sopravvissuti']

# Calcola le medie dei sopravvissuti per età e sesso
mean_survived_male_train = survived_male_train.groupby(pd.cut(ages_train,␣
↪bins=np.arange(0, 100, 10))).mean()
mean_survived_female_train = survived_female_train.groupby(pd.cut(ages_train,␣
↪bins=np.arange(0, 100, 10))).mean()
mean_survived_male_test = survived_male_test.groupby(pd.cut(ages_test, bins=np.
↪arange(0, 100, 10))).mean()
mean_survived_female_test = survived_female_test.groupby(pd.cut(ages_test,␣
↪bins=np.arange(0, 100, 10))).mean()

# Crea un grafico a barre raggruppato per il set di addestramento
plt.figure(figsize=(10, 6))
bar_width = 0.35
index = np.arange(len(mean_survived_male_train))
plt.bar(index, mean_survived_male_train, bar_width, color='blue', label='Maschi␣
↪(addestramento)')
plt.bar(index + bar_width, mean_survived_female_train, bar_width, color='red',␣
↪label='Femmine (addestramento)')
plt.xlabel('Età')
plt.ylabel('Numero medio di sopravvissuti')
plt.title('Distribuzione del numero medio di sopravvissuti per età e sesso␣
↪(addestramento)')
plt.xticks(index + bar_width / 2, mean_survived_male_train.index, rotation=45)
plt.legend()
plt.tight_layout()
plt.show()

# Crea un grafico a barre raggruppato per il set di test
```

```
plt.figure(figsize=(10, 6))
index = np.arange(len(mean_survived_male_test))
plt.bar(index, mean_survived_male_test, bar_width, color='blue', label='Maschi␣
↪(test)')
plt.bar(index + bar_width, mean_survived_female_test, bar_width, color='red',␣
↪label='Femmine (test)')
plt.xlabel('Età')
plt.ylabel('Numero medio di sopravvissuti')
plt.title('Distribuzione del numero medio di sopravvissuti per età e sesso␣
↪(test)')
plt.xticks(index + bar_width / 2, mean_survived_male_test.index, rotation=45)
plt.legend()
plt.tight_layout()
plt.show()
```

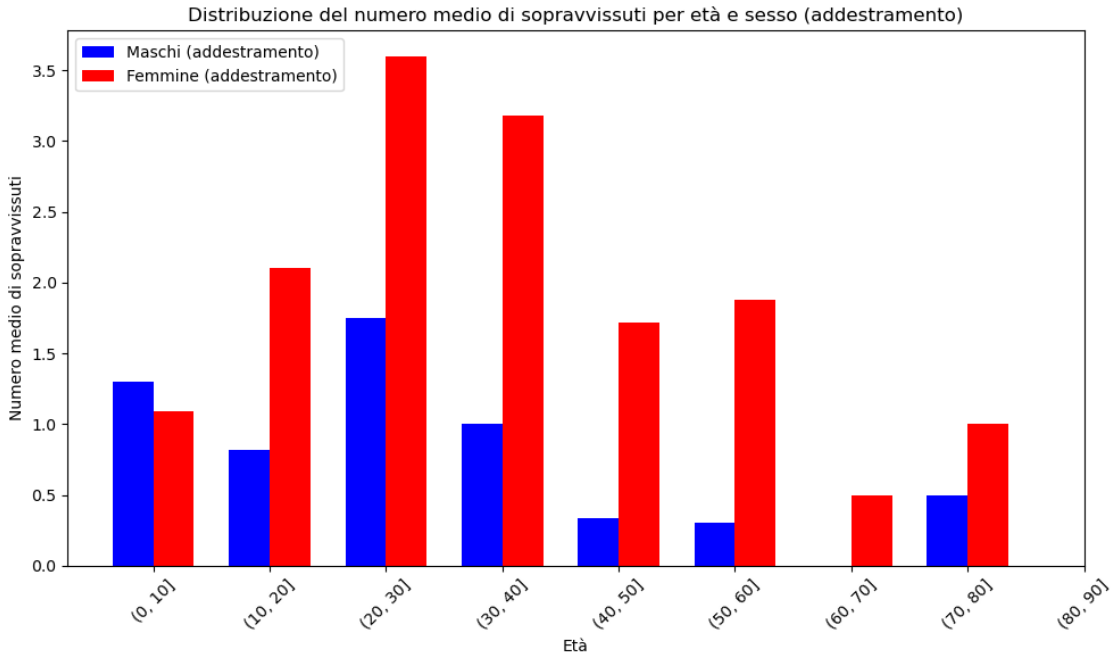

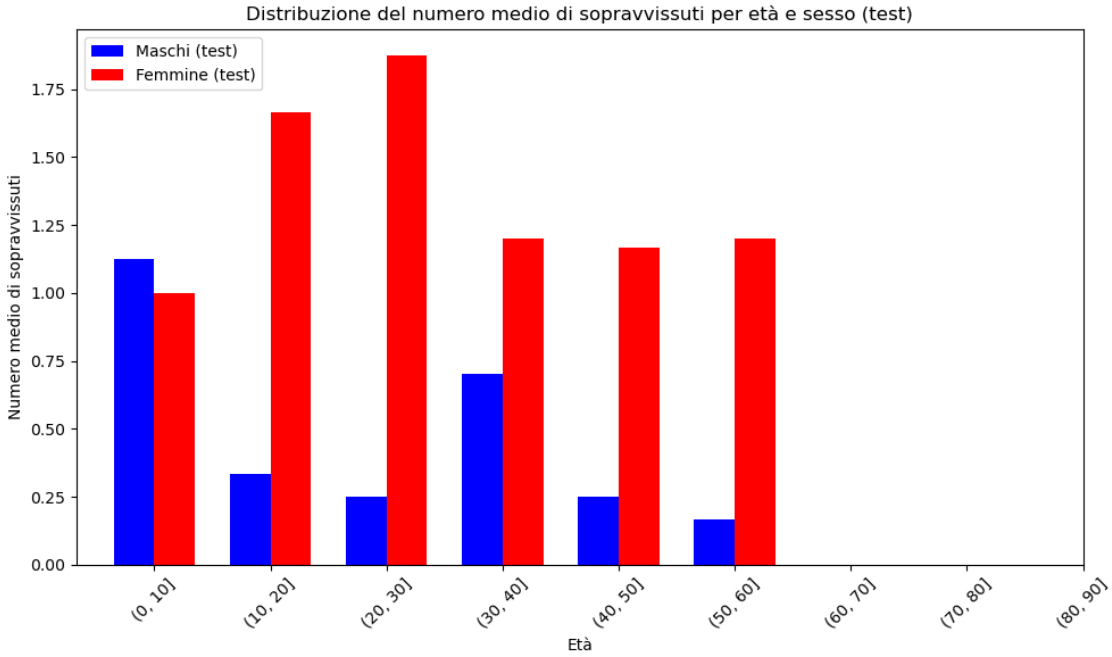
Distribuzione del numero medio di sopravvissuti per età e sesso (test)
Maschi (test)
Femmine (test)
Numero medio di sopravvissuti
0.00
0.25
0.50
0.75
1.00
1.25
1.50
1.75
(0, 10]
(10, 20]
(20, 30]
(30, 40]
(40, 50]
(50, 60]
(60, 70]
(70, 80]
(80, 90]
Età

9 Creazione e valuzatione modelli

[26]:
```
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report

# Creazione dei modelli
logistic_model = LogisticRegression()
tree_model = DecisionTreeClassifier()
forest_model = RandomForestClassifier()

# Codifica la variabile "Sesso" manualmente
X_train['Sesso'] = X_train['Sesso'].map({'male': 0, 'female': 1})
X_test['Sesso'] = X_test['Sesso'].map({'male': 0, 'female': 1})

# Addestramento dei modelli
logistic_model.fit(X_train, y_train)
tree_model.fit(X_train, y_train)
forest_model.fit(X_train, y_train)

# Valutazione dei modelli sul set di test
logistic_pred = logistic_model.predict(X_test)
tree_pred = tree_model.predict(X_test)
forest_pred = forest_model.predict(X_test)

# Calcolo dell'accuratezza dei modelli
logistic_accuracy = accuracy_score(y_test, logistic_pred)
tree_accuracy = accuracy_score(y_test, tree_pred)
forest_accuracy = accuracy_score(y_test, forest_pred)

# Stampa dell'accuratezza dei modelli
print("Accuratezza della regressione logistica:", logistic_accuracy)
print("Accuratezza dell'albero decisionale:", tree_accuracy)
print("Accuratezza della random forest:", forest_accuracy)

# Stampa di altre metriche di valutazione
print("\nRapporto di classificazione per la regressione logistica:")
print(classification_report(y_test, logistic_pred))

print("\nRapporto di classificazione per l'albero decisionale:")
print(classification_report(y_test, tree_pred))

print("\nRapporto di classificazione per la random forest:")
print(classification_report(y_test, forest_pred))
```

```
Accuratezza della regressione logistica: 0.755868544600939
Accuratezza dell'albero decisionale: 0.7089201877934272
Accuratezza della random forest: 0.7089201877934272

Rapporto di classificazione per la regressione logistica:
              precision    recall  f1-score   support

           0       0.79      0.82      0.80       129
           1       0.71      0.65      0.68        84

    accuracy                           0.76       213
   macro avg       0.75      0.74      0.74       213
weighted avg       0.75      0.76      0.75       213


Rapporto di classificazione per l'albero decisionale:
              precision    recall  f1-score   support

           0       0.76      0.77      0.76       129
           1       0.63      0.62      0.63        84

    accuracy                           0.71       213
   macro avg       0.69      0.69      0.69       213
weighted avg       0.71      0.71      0.71       213


Rapporto di classificazione per la random forest:
              precision    recall  f1-score   support

           0       0.76      0.77      0.76       129
           1       0.63      0.62      0.63        84

    accuracy                           0.71       213
   macro avg       0.69      0.69      0.69       213
weighted avg       0.71      0.71      0.71       213
```

[27]:
```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import StratifiedKFold

# Creazione dei modelli
logistic_model = LogisticRegression()
tree_model = DecisionTreeClassifier()
forest_model = RandomForestClassifier()

# Codifica la variabile "Sesso" manualmente
X_train['Sesso'] = X_train['Sesso'].map({'male': 0, 'female': 1})
X_test['Sesso'] = X_test['Sesso'].map({'male': 0, 'female': 1})

# Definizione del numero di fold per la k-fold cross-validation
num_folds = 5

# Definizione della strategia di cross-validation
kfold = StratifiedKFold(n_splits=num_folds, shuffle=True, random_state=42)

# Creazione di un DataFrame per memorizzare le valutazioni dei modelli
model_scores = pd.DataFrame(columns=['Logistic Regression', 'Decision Tree',␣
↪'Random Forest'])

# Valutazione dei modelli utilizzando la k-fold cross-validation
for model, column in zip([logistic_model, tree_model, forest_model],␣
↪model_scores.columns):
    scores = cross_val_score(model, X_train, y_train, cv=kfold,␣
↪scoring='accuracy')
    model_scores[column] = scores

# Creazione del grafico boxplot
plt.figure(figsize=(10, 6))
model_scores.boxplot()
plt.title('Valutazioni dei modelli')
plt.ylabel('Accuratezza')
plt.xlabel('Modelli')
plt.xticks(rotation=45)
plt.grid(True)
plt.show()
```

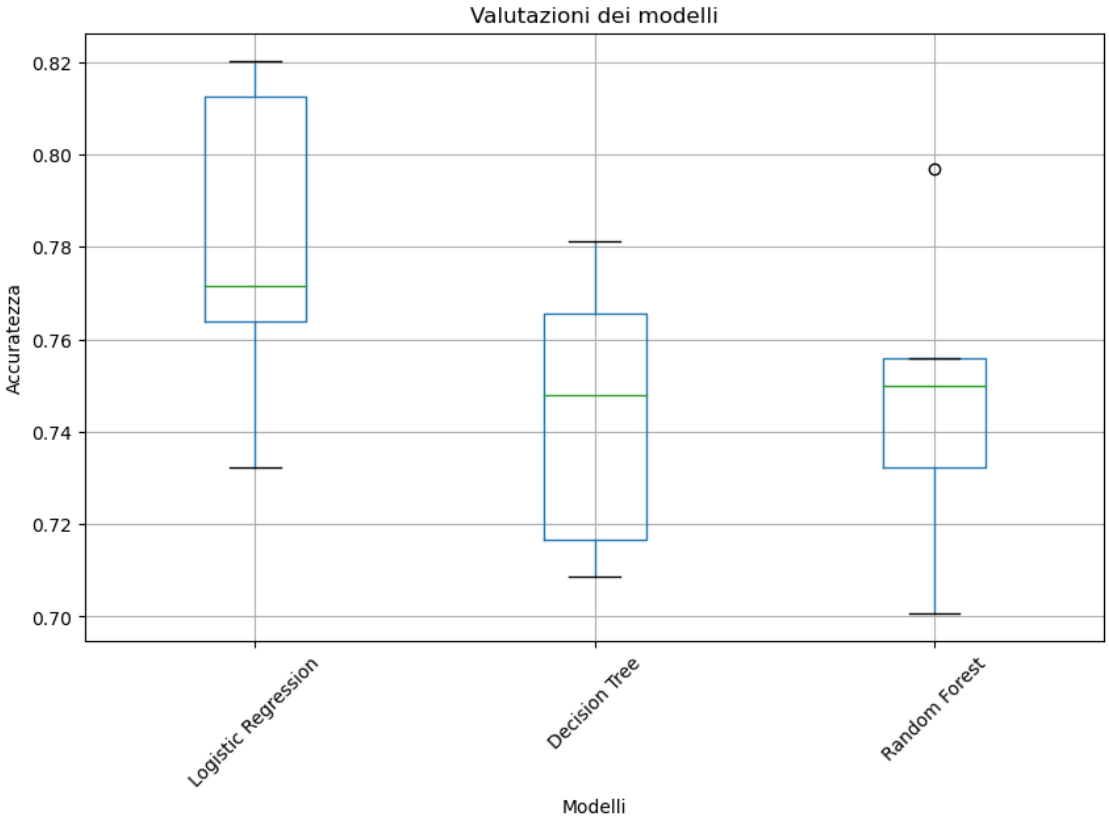
Valutazioni dei modelli
Accuratezza
0.82
0.80
0.78
0.76
0.74
0.72
0.70
Logistic Regression
Decision Tree
Random Forest
Modelli